

1. Бизнес-проблема

Цель: Найти оптимальные пути роста LTV для B2B клиентов через подобранные предложения продуктов.

Задачи:

1. Выделить и охарактеризовать сегменты по LTV
2. Построить LTV модель для прогнозирования среднего значения LTV для нового клиента, основываясь на данных о покупках и профилях клиентов
3. Оценить какие предлагаемые продукты помогут увеличить LTV клиентов через модель NBO
4. Подготовить отчет для менеджмента компании

Проблема: В текущей ситуации компания не может заранее оценить ценность нового клиента.

Это создает ряд бизнес ограничений:

Отсутствие сегментации клиентов по LTV. Без оценки LTV все клиенты рассматриваются одинаково, но на практике клиенты в B2B очень сильно отличаются по своей ценности. Часть клиентов имеет частые покупки и малый средний чек, значительное количество приобретают продукты компании лишь единожды и перестают быть нашим клиентом, и лишь небольшая доля клиентов приносит основную выручку клиентов. Без инструментов оценки LTV компания не может выделить таких клиентов и акцентировать на них свои усилия.

Сложности в прогнозировании общей выручки компании. Отсутствие оценки LTV приводит к невозможности прогнозировать будущую выручку и динамику бизнеса, а также приводит к неэффективности маркетинговых компаний, когда затраты на привлечение клиента значительно превышает его LifeTimeValue.

Отсутствие персонифицированных предложений. Компания не видит, какие предложения наиболее интересны высокодоходным клиентам и не имеет возможность эффективно увеличивать LTV за счет персонифицированных предложений.

Ожидаемый бизнес эффект внедрения модели LTV

Более эффективное распределение маркетингового бюджета Компания сможет инвестировать в каналы привлечения, которые приводят наиболее ценных клиентов.

Улучшение точности финансового планирования. Прогноз LTV новых клиентов позволит более точно оценивать будущую выручку и окупаемость маркетинговых инвестиций.

Персонализация работы с клиентами. Клиентов можно сегментировать по прогнозируемой ценности и использовать различные стратегии по работе с ними. Например, для сегмента с высоким LTV делаем программы лояльности с персональными предложениями, для среднего сегмента стимулируем новые покупки, для низкого минимизируем затраты на удержание.

2. Данные для анализа

Для построения модели прогнозирования Customer Lifetime Value (LTV) были использованы исторические данные о клиентах компании и их покупках.

Данные были представлены в виде двух основных таблиц:


1. companies — информация о клиентах компании
2. revenue — история покупок и заказов клиентов

Использование этих двух источников данных позволяет объединить характеристики компаний-клиентов и их поведенческую историю покупок, что является наиболее важным для прогнозирования LTV.

Произведен первичный анализ данных. Пропуски категориальных признаков sector, segment и industry, kind_of_sale в представленных датасетах заменены на значение "Unknown".

Был проведен анализ числовых признаков с использованием **boxplot-графиков**, чтобы выявить возможные выбросы.


- company_size
- revenue
- segment_2
- product_sum
- product_duration



Как мы видим, данные по выручке компаний "revenue" и покупкам клиентов "product_sum" сильно скошены и имеют выбросы, это стоит учитывать при построении признаков.

Для числовых признаков таблицы companies была построена матрица корреляций.

Heatmap корреляций признаков:



Присутствует связь размера компании и доходности на очищенных от выбросов данных (~ 0.6)
При не удаленных "выбросах" связь еще меньше (~ 0.4), что логично так как абсолютное значение выручки как правило зависит от размера компании. Других сильных корреляций в данных не обнаружено.

Для дальнейших вычислений удаление выбросов не проводилось, так как выявленные отклонения являются частью бизнес особенностей, например таких как длительный срок покупок или большой размер компании.

3. Сегментация

Поскольку исходные данные о покупках представлены на уровне транзакций, следующим шагом была агрегация данных на уровне клиента. Для каждого клиента были рассчитаны следующие агрегированные показатели:

Признак	Описание
total_revenue	Суммарная выручка от клиента
num_orders	Количество заказов
avg_check	Средний чек

total_duration	Суммарная длительность лицензий
unique_products	Количество уникальных продуктов
first_purchase	Дата первой покупки
last_purchase	Дата последней покупки
recency	Количество дней с момента последней покупки
customer_lifetime_days	Время жизни клиента
log_revenue	Логарифмируемое распределение выручки от клиентов

При сегментировании использовалось логарифмирование выручки от клиентов (total_revenue), так как их распределение оказалось сильно асимметричным. Большинство клиентов имеют небольшой LTV, а основную долю выручки приносит небольшая доля клиентов. Это позволило увеличить качество модели уменьшив влияние выбросов и сделав распределение более симметричным.

Для сегментации использовался алгоритм **K-Means clustering**. Он разделяет клиентов на группы с похожим поведением на основании заданных признаков.

Используемые признаки для кластеризации:

- recency
- number of orders
- log revenue
- average check

В результате работы имеем следующие сегменты:

Cluster 0

- Низкая доходность
- Большая часть рынка
- Средняя активность

Стратегия

Массовые предложения:

- базовые тарифы
- недорогие продукты
- акции

Cluster 1

- Низкая доходность
- 20% рынка
- Высокий ресенсу (клиенты давно не покупали)

Стратегия

Реактивация:

- скидки
 - бонусы
 - специальные предложения
-

Cluster 2

- Средняя доходность
- около трети рынка
- активные клиенты

Стратегия

Cross-sell:

- продукты среднего уровня
 - дополнительные сервисы
-

Cluster 3

- Самый высокий средний чек
- небольшое количество компаний

Стратегия

Premium сегмент:

- персональные предложения
 - премиальные продукты
-

Cluster 4

- высокая активность
- высокий LTV

Стратегия

Upsell:

- расширенные пакеты
- премиальные апгрейды

4. Feature Engineering

После очистки данных следующим этапом стал Feature Engineering. Цель данного этапа — преобразовать исходные транзакционные данные в набор признаков, которые максимально полно описывают поведение клиентов, их активность и ценность для бизнеса.

В результате был построен набор признаков, который можно условно разделить на несколько групп:

1. Агрегированные показатели покупок

Они включают в себя:

Признак	Описание
total_revenue	Суммарная выручка от клиента
num_orders	Количество заказов
avg_check	Средний чек
total_duration	Суммарная длительность лицензий
unique_products	Количество уникальных продуктов
first_purchase	Дата первой покупки
last_purchase	Дата последней покупки

Эти показатели позволяют описать общую ценность клиента и интенсивность взаимодействия с продуктами компании.

2. Признаки активности клиентов (RFM)

RFM — это один из наиболее распространенных методов анализа клиентской базы. Он включает в себя признаки recency, frequency и monetary. Как правило именно эти признаки являются наиболее сильными предикторами LTV для клиента.

Recency - время с последней покупки, был рассчитан как

```
df_ltv['recency'] = (snapshot_date - df_ltv['last_purchase']).dt.days
```

Frequency - частота покупок, был рассчитан как

```
df_ltv['purchase_frequency'] = df_ltv['num_orders'] / df_ltv['customer_age'].replace(0,1)
```

Monetary - суммарная выручка по клиенту (total_revenue)

3. Признаки интенсивности покупок

Здесь были выделены такие показатели, как:

Признак	Описание
orders_per_month	Количество покупок в месяц
revenue_per_day	Выручка от клиента в день
revenue_per_day	Выручка за каждый заказ
avg_product_duration	Средняя длительность приобретенной лицензии

Как правило интенсивность покупок влияет на лояльность клиентов и потенциальную величину LTV, поэтому было принято решение использовать данные признаки в модели.

4. Признаки жизненного цикла клиента


Для проверки гипотезы о том, что продукты МТС-Линк наиболее интересны определенным сегментам бизнеса было решено добавить категориальные признаки компаний в features:

Признак	Описание
sector	Отрасль компании
segment	Сегмент компании (малый, средний, крупный бизнес)
segment_2	Подсегмент компании
industry	Индустрии, в которой работает компания
revenue	Выручка компании
company_size	Число сотрудников компании

5. Поведенческие сегменты клиентов

Был также использован атрибут сегмент клиента, ранее выделенный кластеризацией

После построения модели был построен график **SHAP summary plot** для оценки влияния каждого из признаков на итоговое значение LTV.



Как можем видеть на графике, среди 5 наиболее влияющих на итоговое значение признаков есть RFM признаки (recency, purchase_frequency, total_revenue). Высокие recency оказывают сильное негативное влияние на LTV, то есть чем больше времени с последней покупки клиента тем меньше потенциально принесет клиент. Обратная ситуация наблюдается с frequency и total_revenue, они оказывают значительное положительное влияние на LTV.

Среди 5-ти наименее повлиявших на итоговое значение признаков практически все признаки, относящиеся к компании: segment, segment_2, sector, company_size, revenue, что говорит нам о том, что среди клиентов МТС-линк на данный момент нет четко выраженного портрета компании и признаки клиента слабо влияют на то, какое количество выручки мы можем получить от него.

5. Пайплайн построения модели

1. Разделение данных по времени

Данные были разделены на обучающую выборку и тестовую выборку: все транзакции до даты отсечки 2023-01-01 используются для расчета признаков. Транзакции после отсечения в свою очередь используются для расчёта future_revenue.

Это имитирует реальное применение модели – прогноз будущего поведения на основе прошлых данных.

2. Формирование финального датасета

На следующем шаге новые расчетные фичи были объединены с имеющимися признаками для обучения в один датасет. Также пропуски в данных по атрибутам `company_size` и `revenue` были заполнены медианными значениями для улучшения качества предсказания модели.

3. Выбор модели

Предсказание среднего значения LTV в будущем является задачей регрессии. Для её решения был выбран `CatBoostRegressor` – градиентный бустинг, эффективно работающий с категориальными признаками и устойчивый к выбросам.

Основные причины, по которым был выбран Catboost:

- **Смешанный тип данных** – в задаче используются как числовые признаки (сумма покупок, частота, давность), так и категориальные (сектор, сегмент, индустрия). Категориальные переменные имеют большое количество уникальных значений (до 34), и традиционное one-hot кодирование привело бы к сильному увеличению размерности и риску переобучения. CatBoost использует специальный механизм обработки категориальных признаков (счётчики на основе target encoding с добавлением сглаживания), что позволяет извлекать из них максимум информации без риска переобучения и без необходимости ручного кодирования.
- **Наличие пропусков** – в данных о компаниях встречаются пропуски (например, размер компании или выручка за 2023 год), которые необходимо корректно обрабатывать без потери информации. CatBoost автоматически определяет пропущенные значения и учитывает их при построении деревьев, что избавляет от необходимости сложной предобработки.
- **Неоднородность и выбросы** – B2B-клиенты сильно различаются по масштабу: есть как небольшие компании с несколькими покупками, так и крупные корпорации с очень высоким LTV. Модель должна быть устойчива к таким выбросам и не переобучаться на них. Алгоритм использует симметричные деревья и встроенные механизмы регуляризации (`l2_leaf_reg`, `random_strength`), что делает модель менее чувствительной к аномальным значениям LTV крупных клиентов и предотвращает подстройку под шум.
- **Высокая точность при умеренном объёме данных** – градиентный бустинг в целом даёт более точные прогнозы, чем случайный лес или линейные модели, особенно при наличии сложных нелинейных зависимостей. Наши тесты показали, что CatBoost превосходит XGBoost и LightGBM по стабильности на временных срезах (backtesting) и требует меньше ручной настройки гиперпараметров.

Альтернативы и их ограничения:

- **Линейная регрессия** – не справляется с нелинейными зависимостями и требует тщательного преобразования признаков, что увеличивает риск ошибок.
- **Random Forest** – менее точен, чем бустинг, и хуже обобщает на новых данных, особенно при наличии категориальных признаков с большим числом уровней.

- XGBoost/LightGBM – требуют ручного кодирования категорий (one-hot или label encoding), что либо приводит к потере информации, либо к резкому росту размерности. Кроме того, они более чувствительны к выбору гиперпараметров.

4. Обучение и валидация

С помощью библиотеки optuna была произведена оптимизация гиперпараметров модели для увеличения точности и уменьшении средней абсолютной ошибки. Итоговые оптимальные значения параметров:

- iterations = 3104
- depth = 5
- learning_rate = 0.0281
- l2_leaf_reg = 3.25
- bagging_temperature = 3.54
- random_strength = 0.43
- border_count = 163

Модель обучалась на признаках, рассчитанных по данным до 2023 года. В качестве функции потерь использовалась RMSE (среднеквадратичная ошибка), а для мониторинга на валидационной выборке – MAE (средняя абсолютная ошибка), так как она более интерпретируема для бизнеса. Для модели также был добавлен early stopping чтобы избежать возможного переобучения. Если MAE не уменьшается на промежутке в 200 шагов, то мы останавливаем обучение.

6. Оценка и валидация модели

1. Оценка финальной модели на тестовой выборке


После обучения модели мы получили следующие итоговые метрики:

Метрика	Значение
MAE	5 859
RMSE	14 541
R ²	0.87

В среднем модель ошибается на 5,9 тыс. единиц в прогнозе будущей выручки клиента. Учитывая, что средний LTV клиента в выборке составляет около 123 тыс. у.е., ошибка находится в пределах 5%.


Коэффициент детерминации $R^2 = 0,87$ означает, что модель объясняет 87% вариации будущих покупок, что является очень хорошим результатом для LTV моделей. Оставшиеся 13% приходятся на факторы, которые не были учтены в данных, например, внешние экономические условия.

Предсказанные vs Реальные значения



На графике видно, что модель хорошо работает для большинства клиентов (точки концентрируются вдоль линии идеального предсказания). Наибольшие отклонения наблюдаются для клиентов с очень высоким LTV – модель их систематически недооценивает.

Гистограмма ошибок прогноза



Распределение ошибок близко к нормальному с центром около нуля, что говорит об отсутствии систематического смещения. Небольшой хвост отрицательных ошибок соответствует недооценке крупных клиентов.

2. Контроль переобучения

Метрика	Test	Train
MAE	5 380	5 859
RMSE	27 932	14 541
R ²	0.86	0.87

MAE на тесте всего на 9% выше, чем на трейне, что говорит об отсутствии существенного переобучения.

Стоит отметить, что RMSE на трейне выше, чем на тесте – это связано с тем, что в обучающей выборке присутствовало несколько клиентов с экстремально высоким LTV, которые модель не смогла идеально предсказать.

R² на тесте даже немного выше – это подтверждает, что модель хорошо обобщает новые данные.

3. Кросс-валидация на разных временных срезах (Time Series Cross-Validation)

Использована TimeSeriesSplit из библиотеки sklearn. Этот метод разбивает данные на последовательные временные интервалы, где каждый следующий тестовый набор идёт после обучающего.

Результаты:

Период	MAE	RMSE	R ²
1	7 781	26 233	0,66
2	7 622	23 963	0,68
3	7 925	28 895	0,64

Backtesting показал стабильное качество модели на разных временных периодах.

Средний R² составил около 0.64, что говорит о хорошем уровне объяснения вариации LTV при временной валидации.

Средняя абсолютная ошибка MAE = 8055 значительно меньше среднего значения LTV в 122992, которое мы можем наблюдать в датасете.

Также она остаётся стабильной между периодами, что свидетельствует о хорошей обобщающей способности модели и отсутствии переобучения.

Основные вывод:

Разработанная модель обладает высокой точностью, так как R² > 0.85 и стабильна во времени.

Ключевые драйверы показателя LTV – историческая выручка, частота покупок и давность последней покупки.

Модель позволяет ранжировать клиентов по ожидаемой будущей ценности и строить NBO для персонализированных предложений с целью повышения LTV.

Ограничения модели:

- Недооценка очень крупных клиентов. Модель систематически занижает прогноз для клиентов с экстремально высоким LTV (выбросы). Это связано с малым количеством таких примеров в обучающей выборке. Для таких клиентов требуется дополнительная валидация предсказания аналитиком.
- Предположение о стационарности: Модель учитывает данные о продажах из датасета, но упускает макроэкономические факторы, сезонность и изменения в продуктовой линейке ввиду, что является существенным допущением. При изменениях внешней среды точность может снизиться.

Рекомендации по применению:

- Next Best Offer (NBO). Для каждого клиента на основе его кластера и истории покупок необходимо подобрать оптимальный продукт, после чего нужно провести оценку среднего ожидаемого прироста LTV при внедрении NBO
- Мониторинг: Рекомендуется периодически раз в квартал переобучать модель на обновлённых данных, чтобы учитывать изменения в поведении клиентов и появление новых продуктов.

7. Next Best Offer

После прогнозирования LTV была построена система рекомендаций **Next Best Offer (NBO)**.

Цель системы: Предложить клиенту **наиболее релевантный продукт**, который увеличит его будущий доход.

Рекомендации формируются с использованием комбинированного скоринга по следующей формуле:

$$NBO_Score = (0.35 \cdot popularity + 0.25 \cdot value + 0.20 \cdot buy_prob + 0.20 \cdot affinity) \times (1 + ltv_weight),$$
где:

- Popularity - популярность продукта для конкретного кластера
- Value - ценность продукта, средний доход от продукта
- Buy probability - вероятность покупки товара клиентом
- Affinity - связь с уже купленными продуктами
- LTV Weight - коэффициент увеличивающий приоритет клиентов с высоким LTV

Чтобы рекомендации имели смысл, система **исключает товары**, которые клиент уже покупал.

Рекомендованные товары для компаний с низким predicted LTV и высоким recency, что характерно компаниям кластера 1, приходят с флагом discount_strategy: True. Таким образом система дает понять статус активности клиента, и применить к нему стратегию реабилитации.

7.1 Popularity Score

Popularity отражает частоту покупки продукта среди всех клиентов кластера.

Рассчитывается как **число компаний купивших продукт / общее число компаний** в рамках кластера.

Вес - 0.35

7.2 Value Score

Value Score отражает средний доход от продукта.

Вес - 0.25

7.3 Buy Probability

Buy Probability отражает вероятность покупки клиентом.

Она рассчитывается на основе поведения клиента:

- recency
- число заказов
- активность

Вес - 0.20

7.4 Матрица покупок & Affinity Score

Матрица покупок строится на основе транзакций. После преобразования матрица принимает бинарный вид:

company_id	Product A	Product B	Product C
Company1	1	0	1
Company2	1	1	0

Значения интерпретируются следующим образом:

- **1** — продукт покупался
- **0** — продукт не покупался

Для поиска закономерностей в совместных покупках используется алгоритм **Apriori**. Он выявляет **часто встречающиеся наборы товаров**. Таким образом формируется список потенциально релевантных продуктов.

Affinity показывает **связь товара с уже купленными продуктами**. Если товар связан с покупками клиента то $\text{affinity_score} = 1$, иначе $\text{affinity_score} = 0$.

Вес - 0.20

7.5 LTV Weight

Итоговый score учитывает прогноз будущего дохода клиента и увеличивается пропорционально predicted LTV.

8. Результаты

Чтобы оценить бизнес-эффект рекомендаций, была проведена оценка uplift. Uplift показывает насколько может вырасти LTV, если клиент примет одну рекомендацию с вероятностью покупки 20%.

На основе рассчитанных рекомендаций была получена оценка роста LTV.

Метрика	Значение
Средний predicted LTV	~ 36 000
Средний потенциальный LTV	~ 43 000
Средний uplift	~ 7 000

Потенциальный рост составляет **19%**.

Изменение среднего LTV по кластерам:

